

覆盖墙与验证税

RLVR 策略-对-验证器博弈的尖锐相变与设计律

王广宇

billgywang@gmail.com

核心理论 The Wall, the Game, and the Cliff Criterion 在 RLVR 验证上的一个应用(经同构移植;Stage-A 已验证)

July 7, 2026

Abstract

从可验证奖励做强化学习(RLVR)用可执行验证器——答案检查器、模式校验器、单元测试框架——替代人工标签。在优化压力下,策略学会满足验证器却让任务失败:验证器的假阳性变得可获奖。我们分三幕刻画这何时必然发生,经一个显式同构(引理 1)证明到核心理论内核——其高维阈值、信息论逆定理、博弈值与自适应坍塌律都是标注严格度的定理——并在此以 Stage-A 在覆盖记号中验证 (§ 5)。(i) 机制: 面对一个固定验证器,关于错-对的可提取信息在临界覆盖 m^* (压力 $\rho_{\text{cov}}^* = 1 - \sqrt{\gamma/\kappa}/s^2$) 处坍塌,带一个匹配的逆定理——没有对 K 个受检评估的检验能检出缺陷——故验证以悬崖而非斜坡失败。(ii) 博弈值: 当策略选择如何铺展缺陷时,墙成为一个临界漏洞价值 V_{cov}^* ; 铺展到正确性子空间买来一个因子,更聪明的验证器把它夺回,且一旦缺陷的总受检方差暴露它就饱和。(iii) 设计律: 缺陷在奖励相关子空间中的足迹不可消除——策略能把它移入验证器的假阳性区、但在仍收取奖励时无法抹除——故一个瞄准(公开)奖励标准、花掉评估预算的自适应验证器坍塌墙。稳健验证因此不是更好的检查器、而是你添加哪些检查。覆盖区——正确性比测试覆盖更丰富——是 RLVR 默认; core 把其 canonical(集中方向)模型刻画为一个斜坡(检测对覆盖比例 m_{eff}/K_c 线性),精确覆盖律留开。

1 问题、论点与图景

RLVR 用可执行验证器训练策略。优化压力诱发验证器作弊:策略让检查通过而任务是错的(Helff et al. 2604.15149; Ray et al. 2606.01066; Khalifa et al. 2603.07084)。既有工作提供了片段但非相变:一个逐解检测饱和界 $1 - (1 - \bar{p})^{n_{\text{eff}}^*}$ (SAGA 2507.06920); 一个带猜想能力阈值的经济必然性结果(2603.28063); 一个经验复杂度阈值——当漏洞比诚实解更简单时作弊涌现(2605.02964); 以及软件工程不可判定性(Howden 76; Weyuker 86)。缺失的是一个尖锐的高维相变:一个临界验证器覆盖 m^* , 越过它验证器关于错-对的信息坍塌, 以及保持在其之上的代价。

图景(从核心移植)。 我们拒绝宿命式读法(“验证器可被博弈, RLVR 注定失败”)。一个错误完成任务的奖励相关子空间中留下一个统计缺陷足迹。策略能把该足迹重定位进验证器不检查的方向——其假阳性区——但因足迹就是奖励导向的偏离, 它在仍收取奖励时无法抹除它。故验证是否在优化压力下存活并非固定事实、而是一个关于验证器运行哪些检查的博弈之值, 由三个杠杆设定: 覆盖 γ 、评估预算 κ 、以及——决定性地——检查能否瞄准奖励标准。墙对固定验证器真实且尖锐;

它随验证器获得这些而抬高、也可坍塌。关键的 RLVR 转折:奖励标准是公开的(验证器定义通过/失败),故瞄准原则上可用——但真实测试套件覆盖的维度 远少于正确性所有的维度,这恰是墙持续的开放区。

机器映射。 监控墙 $\rightarrow$ **覆盖墙**;零信道维数 $k_{\text{null}} \rightarrow$ **假阳性区维数** $k_{\text{fp}} = D - m_{\text{eff}}$;可监控性税 $\rightarrow$ **验证税** λ_{cov} ;监控器分辨率 $\alpha \rightarrow$ **覆盖** $\gamma = m_{\text{eff}}/D$;数据预算 $n/d \rightarrow$ **验证器功率** $\kappa = K/D$;模型-对-监控器 $\rightarrow$ **策略-对-验证器**。移植近乎逐字;核心论文数值地证明并验证了同一台机器,这是速度与可信度论据。

2 覆盖信道(Stage-A 玩具模型)

任务特征空间 $\mathbb{R}^D$ (D = 任务内在维数)。一个错误完成沿单位方向 $v \in \mathbb{R}^D$ 注入一个显眼度为 s^2 的缺陷(小 s = 微妙错误)。验证器只分辨一个有效维数 m_{eff} 的子空间 S_{ver} (其独立检查),并在 K 个评估实例上累积证据,通过随机设计 $\Phi \in \mathbb{R}^{m_{\text{eff}} \times K}$ 观测偏离并判决缺陷 vs 干净。在优化压力 $\rho \in [0, 1]$ 下,策略把一部分 ρ 的缺陷能量导入维数为 $k_{\text{fp}} = D - m_{\text{eff}}$ 的验证器零空间 $S_{\text{ver}}^\perp$;受检缺陷为 $s^2(1 - \rho)$ 。

序参量:覆盖 $\gamma = m_{\text{eff}}/D (\leftrightarrow \alpha)$;验证器功率 $\kappa = K/D (\leftrightarrow n/d)$;显眼度 s^2 ;压力 ρ ;检查相关性 $\bar{\rho}_{\text{check}}, m_{\text{eff}} = m(1 - \bar{\rho}_{\text{check}})$ (SAGA 有效计数挂钩)。检测是通过设计的尖峰/植入恢复,体边缘为 $\sqrt{m_{\text{eff}}/K} = \sqrt{\gamma/\kappa}$ 。

注 1 (关键建模选择——两个旋钮,分开保持)。朴素的”更多检查”是非单调的:更多检查缩小零空间、但抬高估计噪声地板。**覆盖** γ 缩小隐藏空间 k_{fp} ; **功率** κ (实例预算)击败检测边缘。干净阈值活在二者的相互作用中,而博弈(第二、三幕)在两者上进行。

3 移植:一个可复用的同构

下面的结果不是重新推导的;它们经一个显式映射从核心运送而来。我们把该映射隔离为一个自足引理,使其能被单独引用——被本篇,以及被一个未来统一处理(它是那的共享对象)。

引理 1 (覆盖-核心同构)。Stage-A 覆盖信道是核心理论内核的部分信道模型,在如下重标下

$$\begin{aligned} v \text{ (缺陷方向)} &\leftrightarrow u, \quad m_{\text{eff}} \text{ (有效检查)} \leftrightarrow d_{\text{mon}}, \quad K \text{ (评估)} \leftrightarrow n, \\ \gamma &= m_{\text{eff}}/D \text{ (覆盖)} \leftrightarrow \alpha, \quad \kappa = K/D \text{ (功率)} \leftrightarrow n/d, \quad (S_{\text{ver}}^\perp, k_{\text{fp}}) \text{ (假阳性区)} \leftrightarrow (S_{\text{mon}}^\perp, k_{\text{null}}), \end{aligned}$$

在此有效纵横比精确映射, $\gamma/\kappa = m_{\text{eff}}/K \leftrightarrow d_{\text{mon}}/n$, 检测边缘映为 $\sqrt{\gamma/\kappa} \leftrightarrow \sqrt{d_{\text{mon}}/n}$ 。从 K 个受检偏离恢复缺陷方向 v 逐字是核心的 植入向量 / 尖峰协方差问题。因此那里的每条结果都作为已证陈述转移到此、在同一严格度层级:墙及其逆定理与价格 无条件;博弈值是(重标的)低秩、固定覆盖假设 A1-A4 下的定理;饱和是标度界;自适应坍塌以(重标的)公开且可覆盖 假设 B1-B4 为条件。下面我们逐条陈述并在覆盖记号中数值确认 (§ 5)。

第一幕的其余部分是核心的命题 1-4 及其有效秩推论,经引理 1 读取。

注 2 (同构是一项共享资产). 引理 1 不特属于任何一个博弈:它把两者都识别为通过部分观测信道恢复植入信号的实例,带同一有效纵横比与 同一 BBP 边缘。我们把完整陈述保留在此(它在此做具体工作),写成使一个未来核心论文把它作为共享对象携带;监控是 $(\alpha, n/d)$ 实例,覆盖是 (γ, κ) 实例,而第三幕的覆盖博弈是两实例在难度上仍分道扬镳的唯一区。

第一幕 — 机制:一道尖锐的信息论墙

命题 1 (覆盖墙 / 相变). 在比例区 $D, m_{\text{eff}}, K \rightarrow \infty, m_{\text{eff}}/D \rightarrow \gamma, K/D \rightarrow \kappa$, 验证器的缺陷恢复重叠 $\langle \hat{v}, v \rangle^2$ 对 $\rho < \rho_{\text{cov}}^*$ 严格为正、对 $\rho > \rho_{\text{cov}}^*$ 恰为零, 闭式为

$$\rho_{\text{cov}}^* = \left[1 - \frac{\sqrt{\gamma/\kappa}}{s^2} \right]_0^1 = \left[1 - \frac{\sqrt{(m_{\text{eff}}/D)/(K/D)}}{s^2} \right]_0^1. \quad (1)$$

等价地,在策略的逃避最优处,假阳性区有正测度、且在 $O(1)$ 次奖励查询内可达当且仅当有效覆盖落到临界 $m^* = \gamma^* D$ 之下(γ^* 由 (κ, s) 处的 CGMT 不动点定)。相关检查抬高名义计数, $m_{\text{nominal}}^* = m^*/(1 - \bar{\rho}_{\text{check}})$ 。它是悬崖而非斜坡,且随 D 变尖锐。如核心中,公式被裁剪:当 $s^2 \leq \sqrt{\gamma/\kappa}$ 时受检缺陷已在边缘之下、验证器起始即盲 ($\rho_{\text{cov}}^*=0$); 当 $s^2 \gg \sqrt{\gamma/\kappa}$ 时墙靠近 1。

证明。由引理 1,在重标下这是核心的墙(核心命题 1 及其 BBP 重叠律),边缘 $\sqrt{\gamma/\kappa}$; 裁剪与三个区是核心的区表经映射读取。在覆盖记号中于图 1a,b 验证。 $\square$

推论 1 (有效覆盖:相关/低秩检查抬高墙). 环境 D 在 ρ_{cov}^* 中抵消;进入的是 $\gamma/\kappa = m_{\text{eff}}/K$ 。对检查相关、或可分辨检查协方差 Σ_{ver} 低秩的验证器, m_{eff} 换成其稳定秩 $m_{\text{eff}}^{\text{stab}} = \text{tr } \Sigma_{\text{ver}} / \|\Sigma_{\text{ver}}\| \leq m_{\text{eff}}$ (SAGA 有效计数 $m_{\text{eff}} = m(1 - \bar{\rho}_{\text{check}})$ 是平坦特例,精确)。因更小有效覆盖降低边缘、抬高 ρ_{cov}^* , 相关检查使缺陷更易被压到墙下——实践相关的方向,也是核心推论 1 的覆盖读法(平坦/白化检查精确,一般为 deformed-MP 代理)。

命题 2 (一个基本极限,而非某个估计器(逆定理)). 在墙下($s^2(1 - \rho) < \sqrt{\gamma/\kappa}$),错误与干净完成的受检偏离律相互毗连:一个 Le Cam 二阶矩界给出 $\mathbb{E}_0[L_K^2] \rightarrow (1 - \beta^2/(\gamma/\kappa))^{-1/2} < \infty$,故没有对 K 个受检评估的检验——无论判决规则或 算力——能一致检出缺陷。检测阈值与恢复阈值重合;覆盖墙是信息论的、非某个特定验证器的产物。这关上了”只要造一个更聪明的检查器”。

证明。核心的逆定理(核心命题 2, Le Cam 二阶矩)在引理 1 下、 $\gamma \mapsto \gamma/\kappa$; 于图 1b 验证。 $\square$

命题 3 (覆盖的价格:增长的地板、可行性上限、三重重合). 为在策略优化($\rho \rightarrow \rho_{\text{max}}$)时把对显眼度 s 缺陷的可作弊性保持在 τ 之下,保留的受检缺陷比例 有下界 $1 - \rho_{\text{max}} \geq \beta(\tau)/s^2$,其地板随 $s \rightarrow 0$ 或有效覆盖 γ/κ 下降而增长;因比例 ≤ 1 ,这是一个可行性上限:一旦地板超过 1(等价 $\kappa < c(\tau)\gamma/s^4$, 即实例预算 $K < c(\tau)D\gamma/s^4$, 或 $m_{\text{eff}} < m^*(\tau)$),没有工作点能把可作弊性保持在 τ 之下、验证器被彻底击败。在正斜率假设下(吞吐 / 评估成本损失随强制覆盖上升)验证税 λ_{cov} 随地板增长——”更难任务 + 更多推理算力 $\rightarrow$ 更多作弊”的尖锐形式——且越过上限后没有任何评估预算能买到目标级验证。在 m^* 处三个事件重合:墙、验证影子价格发散、以及缺陷能量完全越入验证器零空间——一个序参量 $\beta_{\text{sig}} \rightarrow 0$,三个读数。

证明。核心的命题 3(能量地板,严格)与命题 4(三重重合)在引理 1 下;可行性上限读法是核心的有界比例修正,斜率 κ_{tax} 任务校准(Stage A.5)。设定地板的墙位置于图 1a,b 验证。 $\square$

第二幕 — 墙的高度是一个博弈值

至此缺陷方向 v 与压力 ρ 是外生的。实际中策略选择如何把缺陷铺展到奖励相关子空间以最小化可检测性、同时仍是一个成功漏洞(交付漏洞价值 V),而验证器选择检查哪个子空间。墙成为此博弈之值——一个临界漏洞价值 V_{cov}^* ,而非强加的压力。

命题 4 (内生缺陷谱). 设奖励相关(正确性)子空间维数为 K_c 、价值密度为 g ,验证器有固定覆盖边缘 $\sqrt{\gamma/\kappa}$ 。极小极大均衡 把缺陷平摊铺于 K_c 个正确性方向(每个亚临界)。漏洞不可检测当且仅当交付的漏洞价值低于临界值:

$$\text{覆盖(峰值)验证器: } V < V_{\text{peak}}^* = gK_c\sqrt{\gamma/\kappa}; \quad \text{最优验证器: } V < V_{\text{opt}}^* = g\sqrt{K_c\gamma/\kappa}.$$

故 ρ 内生;正确性秩 K_c 是策略的资源(铺展缺陷使每个检查保持在阈下),对峰值验证器值一个因子 K_c 、但对 最优验证器只值 $\sqrt{K_c}$ ——验证器精巧度差距恰为 $\sqrt{K_c}$ 。($K_c = 1$ 退回命题 1。)这在 (重标的)假设 A1-A4 下成立:正交缺陷方向、瞄准以含正确性子空间的固定覆盖($K_c \leq m_{\text{eff}}$)、亚广延 $K_c = o(D)$ 、以及二阶(聚合残差)签名。

证明。核心的博弈值定理(核心命题 5,在 A1-A4 下证明;最优支经其附录 C 的多尖峰二阶矩)在引理 1 下,边缘 $\sqrt{\gamma/\kappa}$ 、 g 为正确性价值密度。于图 1c 验证。 $\square$

命题 5 (铺展自我拆台: $\sqrt{K_c}$ 优势饱和). 一个广延缺陷($K_c = \Theta(D)$)把总受检残差方差抬高一个广延量,平凡聚合覆盖统计量 $\hat{T} = \frac{1}{K} \sum_i \|\Phi \text{残差}_i\|^2$ 分辨它。故可藏漏洞价值被独立于 K_c 地封顶, $V_{\text{ext}}^* = \Theta(g/\sqrt{\gamma\kappa})$, $\sqrt{K_c}$ 增长在正确性秩 $K_c^* = \Theta(1/\gamma^2)$ 处饱和:越过它,把缺陷铺得更宽只暴露更多总残差。精确最优验证器值是 Marchenko–Pastur 体与受检缺陷谱的自由乘性卷积,夹逼于峰值(尖峰)界与迹(聚合)界之间。

证明(标度)。核心的饱和命题(核心命题 6)在引理 1 下:广延缺陷抬高总受检残差,一旦清过其噪声地板 $\propto \sqrt{1/(\gamma\kappa)}$ 即被聚合统计量分辨;封顶 $V_{\text{ext}}^* = \Theta(g/\sqrt{\gamma\kappa})$ K_c -无关,精确最优值是自由卷积边缘,如陈述般被夹逼。 $\square$

第三幕 — 设计律:瞄准是决定性的

命题 6 (自适应覆盖坍塌墙)。RLVR 转折:奖励标准是公开的——验证器定义通过/失败,故它知道奖励相关子空间。设验证器自适应 其检查、把覆盖瞄准任意选择处。当正确性子空间适配覆盖预算 ($K_c \leq m_{\text{eff}}$)时,验证器瞄准它并测量总奖励 相关残差。交付漏洞价值 V 迫使奖励相关残差 $\propto V/g$ ——恰是瞄准覆盖检验所测——故没有缺陷谱逃脱(检验铺展不变),可藏漏洞价值随评估预算 K 增长坍塌到 $V_{\text{adapt}}^* = \Theta(g\sqrt{K_c/K}) \rightarrow 0$ 。命题 4-5 的铺展优势蒸发:策略对固定测试套件所藏,瞄准验证器抓住。覆盖墙只在验证器 无法瞄准其检查、或评估预算匮乏时保护利用者。假设(重标的 B1-B4):奖励标准(从而正确性子空间)公开;验证器可 重新瞄准其覆盖且 $K_c \leq m_{\text{eff}}$;它使用总奖励相关残差(聚合)检验;且漏洞价值以奖励相关残差交付,故被迫且不可约。

证明。核心的自适应坍塌命题(核心命题 7,以 B1-B4 为条件)在引理 1 下; $V_{\text{adapt}}^* = \Theta(g\sqrt{K_c/K}) \rightarrow 0$ 随评估预算 K 增长。于图 1d 验证。 $\square$

Box 1:稳健验证器的设计律。 分析是处方性的、非宿命的——它说如何把覆盖墙保持得高。

- 把检查瞄准奖励标准。缺陷足迹活在奖励被收集之处——而验证器定义那(通过/失败公开)。先覆盖那些 维度(命题 6);瞄准胜过任何固定通用测试套件。
- 让覆盖匹配正确性秩。保持 $m_{\text{eff}} \geq K_c$ 使正确性子空间适配;低于此,覆盖博弈留下可利用缝隙。
- 花掉评估预算。墙高按 $\sqrt{1/K}$ 标度:更多评估实例驱动 $V^* \rightarrow 0$ 。
- 用聚合(二阶)覆盖统计量,而非逐检查通过率:尖锐墙是协方差尖峰现象;逐检查通过/失败是光滑(无阈值)情形。
- 下一个添加最去相关的检查(next_check);用覆盖仪表读墙高、并在墙前加固——通过率在坍塌前 不给预警。

注 3 (覆盖区是斜坡(据 core),且它就是 RLVR 默认)。命题 6 在覆盖能张成正确性($K_c \leq m_{\text{eff}}$)时关闭博弈。其补 $K_c > m_{\text{eff}}$ ——正确性比测试覆盖更丰富——是实践主导区:单元测试从不张成一个程序的所有正确性维度,验证器检查一个 m_{eff}/K_c 比例,策略把漏洞藏于 未检查的方向。core 把这个覆盖博弈的 canonical(集中方向)版本刻画为一个斜坡、而非尖锐阈值:被迫随机化使 检测对覆盖比例线性, $p_{\text{det}} = m_{\text{eff}}/K_c$ 。故这不是无预警的坍塌、而是平滑、可定价的退化,其陡度是覆盖-正确性比;完整博弈及其精确覆盖律是留开的一块。不同于监控(自适应监控器可能直接获胜),在 RLVR 中此 覆盖斜坡是默认:正确性常态地跑赢覆盖,这正是覆盖墙——以及瞄准、花预算使 m_{eff} 追踪 K_c 的纪律——在 实践中重要的原因。

4 CGMT 辅助问题梗概(共享机器)

从受检偏离恢复 v 是尖峰协方差 / 植入向量问题,一个带高斯设计 $G \in \mathbb{R}^{m_{\text{eff}} \times K}$ 的极小极大:

$$\Phi(G) = \min_{\|w\|=1} \max_{\|q\| \leq 1} q^\top (G/\sqrt{K})w + \psi(w, q; s\sqrt{1-\rho}).$$

CGMT 把它约化为辅助问题 $\phi(g, h) = \min_w \max_q \|q\| g^\top w + \|w\| h^\top q + \psi$,标量化为一个 2-3 维不动点。信号序参量 $\beta_{\text{sig}}(v\text{-重叠})$ 恰在 $s^2(1-\rho) < \sqrt{m_{\text{eff}}/K}$ 时为 0,给出 ρ_{cov}^* 与命题 1 的尖锐性;在可检测性约束中对值函数求导得命题 3 的税地板;第二个副本给出逆定理(命题 2)。这与核心的 CGMT 梗概结构上完全相同——移植近乎逐字,核心论文已在 仿真中证明并验证了同一个不动点、逆定理、博弈值与自适应坍塌律。

5 Stage-A 数值验证(覆盖记号)

我们在覆盖记号中重跑核心的 Stage-A 协议(numpy,CPU),即在覆盖 γ 、功率 κ 、边缘 $\sqrt{\gamma/\kappa}$ 下从 K 个受检偏离恢复一个植入缺陷 v ;显眼度 $s^2=1.414$ 故在 $\gamma=0.5, \kappa=1$ 时 $\rho_{\text{cov}}^*=0.5$ 。以下所有数值由这套重参数化产生(coverage_stageA.py);无一手工设定。

四条核心论断恰如同构(引理 1)所预言地在覆盖信道上成立:墙位置匹配 (1) 并随 D 变尖锐;它随验证器功率 κ 移动;博弈值显示 $\sqrt{K_c}$ 精巧度差距;瞄准验证器坍塌固定套件看不见的墙。这是”同一台 机器,已验证”论据在 RLVR 记号中的具体化;税斜率与一个真实玩具验证器是 Stage A.5。




Figure 1: 覆盖墙, Stage A。 (a) 缺陷检测 AUC 对压力 ρ : ρ_{cov}^* 处的坍塌随任务维数 $D \in \{100, 300, 900\}$ 变尖锐——真相变, 非有限尺寸斜坡。 (b) 更弱验证器(更小功率 κ) 在更低压力处失明: ρ_{cov}^* 对 $\kappa \in \{0.5, 1, 2\}$ 移到 0.29, 0.50, 0.65, 匹配 (1)。 (c) 博弈值: 测得临界漏洞价值对峰值(覆盖)验证器按 $gK_c\sqrt{\gamma/\kappa}$ 增长、但对聚合验证器只按 $g\sqrt{K_c\gamma/\kappa}$ —— $\sqrt{K_c}$ 差距(命题 4); 聚合统计量是实现其一部分的实用代理, 故测得差距是一个保守下界。 (d) 自适应坍塌: 完全铺于正确性子空间, 固定测试套件失明 ($\text{AUC} \approx 0.5$), 但测量总奖励相关残差的 瞄准验证器抓住漏洞 ($\text{AUC} \rightarrow 0.93$)——铺展对它无用(命题 6)。

6 仪表: 覆盖仪表(接口)

一个验证器侧诊断; `next_check` 是验证器的博弈动作(第三幕), 而非一个工具函数。

- `fp_region_dim(task_geom, verifier_op) →  $k_{\text{fp}} = D - m_{\text{eff}}$` : 偏离协方差在检查可分辨算子之外的参与比 (对应 `null_channel_dim`)。
- `coverage_wall_estimate(s_hat, gamma, kappa) →  $\hat{\rho}_{\text{cov}}^*$` , 带自举带; 当工作点在 墙的 δ 内时标记。
- `verification_price(completions, labels) →  $\hat{\lambda}_{\text{cov}}$` : 每单位保留检测信息的边际任务/吞吐成本, 自举 CI。
- `next_check(verifier, task_geom) →` 添加最能缩小假阳性区(最去相关)的检查——验证器的最佳响应动作; 为 2606.01066 的经验加固消融奠定基础。
- `StoppingRule`: 当 $\hat{\rho} \rightarrow \hat{\rho}_{\text{cov}}^*$ 或 $\hat{\lambda}_{\text{cov}}$ 陡增时暂停 RLVR / 标记验证器 —— “在墙前加固”。

7 阶段计划(证据层级)

Stage A(已完成; § 5, 图 1)。带受控 $(D, m_{\text{eff}}, K, s)$ 的合成覆盖信道: 确认了 (a) 缺陷检测 AUC 越过 ρ_{cov}^* 从 1.0 $\rightarrow$ 0.5 坍塌并随 D 变尖锐; (b) 墙如闭式预言般随验证器功率 κ 移动; (c) 博弈值显示 $\sqrt{K_c}$ 差距; (d) 瞄准验证器坍塌固定套件看不见的墙。(这是同一核心仿真的重参数化, 现以覆盖记号重现。) Stage A.5(下一步)。一个真实玩具验证器(数学最终答案 / JSON 模式 / 玩具单元测试) + 一个微型 REINFORCE 策略: 漏洞起始须落在预言的 m^* 、且 `next_check` 须先发制人; 此阶段也校准唯一的自由税斜率。论断保持定性。Stage B(已规定; GPU)。真实 RLVR 智能体编码, 在真实测试套件验证器下; 证伪: 墙须出现在 $(D - m_{\text{eff}})/\kappa$ 预言处, 且税须随缺陷微妙度 / 任务维数标度。真值数据集: Terminal-wrench (2604.17596)、ImpossibleBench(2510.20270)、Countdown-Code(2603.07084)。

8 这是什么,不是什么

这是一篇刻画型姊妹论文:承重结果——一个相变、一个信息论逆定理、一个博弈值、一条自适应坍塌设计律——在此经同构(引理 1)证明到核心的定理、并在 Stage-A 验证 (§ 5),继承核心的严格度层级(墙/逆定理/价格无条件;博弈值在 A1-A4 下;饱和为标度界;自适应坍塌以 B1-B4 为条件)。在真实 RLVR 验证器上的验证需要 Stage B——尚未使用任何真实验证器。为自足起见,附录 A 从 CGMT 不动点在覆盖记号中重述并证明墙与逆定理,故本篇中心主张无需核心即成立。严格地售为:一个尖锐覆盖阈值 m^* ;一个验证税发散;一个带饱和铺展优势的博弈值;一条设计律(瞄准坍塌墙)配一个读墙高、给下一个检查定价的仪表;以及经验加固曲线的闭式预言。**不是**“验证器可被博弈”(已被占:2604.15149、2606.01066);**不是**“有限评估 $\rightarrow$ 必然扭曲”(已被占:2603.28063、Holmström–Milgrom 91);**不是**检测工具(已被占:IPT、模糊测试、梯度指纹)。新颖处是 优化何时必须抵达假阳性区、覆盖要付什么、以及验证器必须做什么才能保持墙高。

A 自足内核:覆盖墙,以覆盖记号证明

正文经引理 1 从核心运送其结果。为自足起见,我们重述承重结果——墙及其逆定理——并给出一个不依赖阅读核心的覆盖记号证明。(这是同一个 CGMT 不动点;我们保留于此使本篇中心主张独立成立。)

设置,重述。 一个错误完成沿单位方向 $v \in \mathbb{R}^D$ 植入一个显眼度为 s^2 的缺陷。验证器分辨一个有效维数 m_{eff} 的子空间 S_{ver} 并累积 K 个评估,通过一个 i.i.d. 高斯设计 $G \in \mathbb{R}^{m_{\text{eff}} \times K}$ 观测偏离。压力 ρ 下策略把一部分 ρ 的缺陷导入 $S_{\text{ver}}^\perp$,沿可见分量 $\tilde{v}$ 留下受检缺陷 $\beta = s^2(1 - \rho)$ 。记有效纵横比 $\Gamma \equiv \gamma/\kappa = m_{\text{eff}}/K$;边缘为 $\sqrt{\Gamma}$ 。

定理 1 (覆盖墙 + 逆定理,自足). 在比例区 $m_{\text{eff}}, K \rightarrow \infty, m_{\text{eff}}/K \rightarrow \Gamma$: (i,恢复) 验证器的缺陷恢复重叠 $\langle \tilde{v}, v \rangle^2$ 为 $[(1 - \Gamma/\beta^2)/(1 + \Gamma/\beta)]_+$,对 $\beta > \sqrt{\Gamma}$ 严格为正、对 $\beta \leq \sqrt{\Gamma}$ 恰为零,即零当且仅当 $\rho \geq \rho_{\text{cov}}^* = [1 - \sqrt{\Gamma}/s^2]_0^1$; (ii,逆定理) 对 $\beta < \sqrt{\Gamma}$,错误与干净完成的受检偏离律毗连——Bayes 似然比二阶矩 $\mathbb{E}_0[L_K^2] \rightarrow (1 - \beta^2/\Gamma)^{-1/2} < \infty$ ——故没有对 K 个受检评估的检验能一致检出缺陷。两阈值在 $\beta = \sqrt{\Gamma}$ 处重合。

证明(CGMT 不动点,覆盖记号)。 恢复 v 是植入向量问题 $\Phi = \max_{\|w\|=1} \max_{\|q\| \leq 1} \frac{1}{\sqrt{K}} [w^\top Gq + \sqrt{\beta} (w^\top \tilde{v})(\eta^\top q)]$, $\eta \in \mathbb{R}^K$ 为植入载荷。由凸高斯极小极大(Gordon)替换,双线性项 $w^\top Gq$ 换成 $\|q\| g^\top w + \|w\| h^\top q$ ($g \in \mathbb{R}^{m_{\text{eff}}}, h \in \mathbb{R}^K$ 标准高斯),并在重叠 $\mu = \langle w, \tilde{v} \rangle$ 上标量化(优化冗余方向、用 $m_{\text{eff}}/K \rightarrow \Gamma$)把辅助问题约化为一维势

$$\Phi_{\text{AO}}(\mu) = \sqrt{\Gamma(1 - \mu^2)} + \sqrt{1 + \beta\mu^2} = (\sqrt{\Gamma} + 1) + \frac{\mu^2}{2}(\beta - \sqrt{\Gamma}) + O(\mu^4).$$

故 $\beta < \sqrt{\Gamma}$ 时 $\mu = 0$ 是唯一极大点, $\beta > \sqrt{\Gamma}$ 时非平凡分支分岔(叉式);解 $\Phi'_{\text{AO}}(\mu) = 0$ 得重叠 $\mu^{*2} = (\beta^2 - \Gamma)/(\beta(\beta + \Gamma))$,它等于 (i) 的 BBP/Paul 特征向量重叠。故信号重叠为 0 当且仅当 $\beta \leq \sqrt{\Gamma}$,即 $s^2(1 - \rho) \leq \sqrt{m_{\text{eff}}/K}$,即 $\rho \geq \rho_{\text{cov}}^*$ ——在 μ 中连续但在 ρ 中非解析(尖锐性)。对 (ii), v 均匀先验下的单植入方向 Le Cam 二阶矩为 $\mathbb{E}_0[L_K^2] \rightarrow (1 - \beta^2/\Gamma)^{-1/2}$,有限当且仅当 $\beta < \sqrt{\Gamma}$;有界二阶矩给出毗连,从而无一致检验。一致性检验: $\mu=0$ 势值 $1 + \sqrt{\Gamma}$ 匹配 Marchenko–Pastur 边缘,重叠匹配 BBP;两者都与 § 5 的 Stage-A 仿真一致。□

本附录的范围。 这只重述墙与逆定理——本篇最依赖的两条陈述——使中心主张自足。博弈值(命题 4)、饱和(命题 5)与自适应坍塌(命题 6)在引理 1 下经同一不动点转移;其完整证明在核心 (或未来的核心),其 Stage-A 确认在 § 5。我们以标准 Gordon 替换的层级呈现 CGMT 约化,而非自足正则性 证明;其有效性依赖标准 CGMT 假设加上上述一致性检验与仿真。

参考文献(非正式)

Helff 2604.15149 · Ray 2606.01066 · Khalifa 2603.07084 · SAGA 2507.06920 · Finite-Evaluation-Equilibrium 2603.28063 · Reward-Hacking-Benchmark 2605.02964 · ImpossibleBench 2510.20270 · Terminal-wrench 2604.17596 · Goodenough–Gerhart 75 · Howden 76 · Budd–Angluin 82 · Weyuker 86 · DeMillo 78。核心理论: The Wall, the Game, and the Cliff Criterion: sharp thresholds for recovering a planted signal through a partial channel(全部证明、CGMT 不动点、博弈值、饱和、自适应坍塌、悬崖判据)。姊妹应用: The Monitoring Wall and the Monitorability Tax($(\alpha, n/d)$ 思维链实例)。