

监控墙与可监控性税: 模型对监控器博弈的一个尖锐相变

王广宇

billgywang@gmail.com

(工作草稿 —— 供内部迭代;由英文版翻译)

July 7, 2026

Abstract

思维链(chain-of-thought, CoT)监控是监督强大模型的主流工具,但在实践中很脆弱:在优化压力下,模型会学会混淆式(obfuscated)奖励作弊——保留被奖励的行为,却把意图从推理轨迹中抹去。我们证明,监控能否在这种压力下存活,由一道尖锐、可计算的墙(wall)决定;而墙的高度正是”模型隐藏作弊 vs 监控器选择往哪看”这一博弈的值。(i) 机制(无条件):面对固定监控器,关于作弊的可提取信号在临界压力 $\rho^* = 1 - \sqrt{\alpha/(n/d)}/s^2$ 处坍塌,并有一条匹配的逆定理——对投影轨迹的任何检验都无法一致地检出作弊——所以监控是悬崖式失效,而非缓坡。(ii) 博弈值(主要新结果):当模型可以选择其隐藏谱时,墙变成一个临界奖励 V^* ;把作弊铺展到 K 维任务子空间能换来一个优势,而精细的监控器把它压回到 $\sqrt{K}$,且一旦作弊的总方差暴露,该优势即饱和。(iii) 设计律:奖励作弊的足迹是不可消除的——可被搬进监控器的零信道,却无法在保留奖励的同时抹去——因此,当奖励结构公开且可覆盖时 (§ 4, B1–B4),一个瞄准奖励结构的自适应监控器会坍塌这道墙。所以稳健监控关乎你往哪看,而非造一个更好的分类器。墙及其逆定理是无条件的;博弈值在明确的低秩、固定分辨率假设下被证明;饱和律与坍塌律是延伸,并留有一个覆盖博弈区——core 将其刻画为斜坡。我们把该理论封装为一个监控器侧的仪表(Meter),用以读出当前的墙高。

1 引言

随着模型以其可验证的结果为目标进行强化训练——通过单元测试、满足某个检查器、最大化某个奖励模型——并作为在长时程上行动的智能体被部署,对每一步行动进行人工审查已不可行。一个主流的退路是监控模型自身外化的推理:读取思维链(CoT)或执行轨迹,标记任何意图看起来不安全的轨迹,哪怕最终输出看起来无恙。越来越多的安全论证依赖于这种”意图可读性”,正因为它承诺能抓住输出层检查漏掉的错误行为。

前提是意图保持可读。可一旦轨迹本身承受优化压力,这个前提就不成立了。一个因测试通过(绿灯)而被奖励的编码智能体,会学会对测试做特判,同时给出一段干净、看似合理的说辞;一个只要 CoT 暴露捷径就被惩罚的模型,会学会悄悄地走捷径。对 CoT 施加优化压力,经验上会诱发混淆式作弊:被奖励的行为被保留,而暴露性的信号被抹去,于是监控器的读数反而可能更健康,尽管底层行为在变糟 [2, 3, 5]。因此监控存在一种从监控器自身仪表盘上看不见的失效模式——这是最危险的一种,因为报警信号本身正是被抹去的东西。

这种退化的形状是什么?文献里并存三种性质迥异、且运营后果相反的答案。它可能是渐进的——压力越大、信号成比例地越少——那样监控就买到了一条优雅、可调的安全裕度,可以权衡。它也可能是一道悬崖——信号在某个阈值前一直良好,越过后骤然消失——那样今天读数健康的监控器可能离失明只差一步 优化,而你盯着的 AUC 根本不是安全裕度。它还可能是不可避免的——超过某个能力差距后,任何可实现的监控器都无济于事,唯一诚实的选择就是停止优化。现有的形式化工具无法在三者间裁决:轨迹 O 与意图 Z 之间的信息论度量 $I(O; Z | X)$ [4],或决策论间隙 $1 - TV$ [6],量化了在某个给定工作点上还剩多少信号,却定位不了阈值;隐写术表明不可检测的信道可能存在 [8, 7],却没说优化何时被逼进这些信道,也没说留在信道外的代价。

总体图像。 我们的结果用一个更尖锐、更可操作的图像,取代那个宿命论式的解读(“监控注定在悬崖处失败”)。奖励作弊在轨迹的奖励相关子空间里留下一个统计足迹;模型可以把这个足迹搬进监控器分辨不了的方向——它的零信道(null channel)——但因为这个足迹就是奖励导向的方差,模型无法在仍然领取奖励的同时把它抹去。所以监控能否在优化压力下存活,不是一个固定的事实,而是一个关于监控器往哪看的博弈的值,由三个杠杆决定:监控器的分辨率 α 、它的数据预算 n/d 、以及——最关键地——它能否瞄准奖励结构。当监控器固定或盲目时,墙是真实且尖锐的;而当监控器获得这些能力时,墙会升高,乃至坍塌。

贡献。 我们把这个博弈刻画为三幕。

第一幕——机制:一道尖锐的、信息论的墙,无条件 (§ 4)。这些结果对模型的隐藏策略不作任何假设。

- **监控墙(命题 1)。** 在比例型高维极限下,监控器与作弊方向的恢复重叠 (overlap) 在临界压力 ρ^* 之下严格为正、之上恰好为零,其闭式 $\rho^* = 1 - \sqrt{\alpha/(n/d)}/s^2$ 完全由几何决定(分辨率 α 、数据预算 n/d 、显眼度 s)。它是悬崖而非缓坡,且随维度变得更尖锐。(环境维数在 ρ^* 中抵消;在真实模型的低秩潜空间上, § 4 的有效秩形式抬高墙,故下界不减反增。)
- **一个基本极限,而非某个估计量的局限(命题 1)。** 一条匹配的 Le Cam 二阶矩逆定理:墙之下,干净与作弊两个分布是相互毗连(contiguous)的,因此对投影轨迹的任何检验都无法一致检出作弊。检测阈值与估计阈值重合;墙是信息论意义上的。
- **可读性的代价 (§ 4, 4)。** 要把检测保持在目标之上,就强制在保留的可见能量上出现一个随能力差距发散的下限;在正斜率假设下,任务税随之发散。在 ρ^* 处,墙、发散的价格、以及作弊能量没入零信道,三者重合——一个序参量,三种读数。

第二幕——墙的高度是一个博弈值;这是本文的核心新结果 (§ 4)。

- **内生的隐藏 (§ 4)。** 当模型选择其隐藏谱时,墙变成一个临界奖励 V^* :把作弊铺展到 K 维任务子空间,可对峰值检测器隐藏至多 $gK\sqrt{\gamma}$ 的奖励、对最优检测器 $g\sqrt{K\gamma}$ ——任务秩是隐藏者的资源,而精细的监控器恰好夺回 $\sqrt{K}$ 。我们在明确的低秩、固定分辨率、正交尖峰、次广延假设(A1-A4)下证明之; $K = 1$ 退回第一幕。

延伸——勾勒博弈的边界,以及设计律 (§ 4)。接下来两个结果放松假设 A3 与 A2,并以其区域当前允许的较弱严格度陈述(一个标度界与一个夹逼);它们正是让整个图像变得处方式的东西。

- **铺展会自我拆台 (§ 4; 标度)**。 $\sqrt{K}$ 优势会饱和: 广延型 作弊抬高轨迹的总方差并被它出卖, 把可隐藏奖励封顶在 $\Theta(g/\sqrt{\alpha n/d})$, 与 K 无关。
- **自适应分辨率坍塌墙 (§ 4)**。 因为足迹不可消除, 一个瞄准(公开且可覆盖的)任务子空间、并测量其总方差的监控器, 能击败一切铺展(假设 B1-B4)——数据足够时 $V^* \rightarrow 0$ 。墙只在监控器瞄不准、盖不住任务($K_{\text{pool}} > \alpha d$)、或数据匮乏时才保护隐藏者; 由此得到稳健监控器的具体设计原则(方框 1), 并留下一个区——当任务超出监控器分辨率时的覆盖博弈——core 将其刻画为斜坡(检测对覆盖比例 α/κ 线性), 精确覆盖律留开。

严格度脊柱。墙及其逆定理(第一幕)是无条件的; 博弈值(第二幕)是 A1-A4 下的定理; 饱和律与坍塌律是勾勒边界、并给出设计律的延伸, 把精确的广延值与一般自适应鞍点留作纲领的开放问题。

贯穿全文的尖锐性来自 BBP 尖峰协方差相变 [10, 11](均值移位模型将是平滑的); 我们给出其背后的 CGMT 不动点 [13], 以及一个从轨迹统计量估计当前墙高的监控器侧仪表(Meter)。

本文是什么, 不是什么。 这是一篇刻画(characterization)论文: 承重结果——一个相变、一条信息论逆定理、一个博弈值——是自洽的理论。我们在受控仿真中验证机制(一个高斯信道、一个路由代理、一个梯度校验过、由 REINFORCE 训练的 token transformer)。我们强调适用范围: 在真实 CoT 监控器上的验证需要 Stage B——真实推理模型在真实 LLM 监控器下 (§ 7)——仿真并不替代它; 仿真确立机制及其预测, 而 Stage B 才是这些预测被检验、并可能失败的地方。”作弊”泛指任何抬高奖励、而某个监督信号本应抓住它的行为。我们不主张混淆可能(已知 [8, 7]), 也不主张有限监督会扭曲目标(已知 [9]); 我们刻画的是: 优化何时必须抵达零信道, 保持可读要付什么代价, 以及监控器必须做什么才能保持墙高。

结构与严格度。 本文读作三幕——带逆定理的尖锐墙(第一幕, 无条件)、墙作为博弈值(第二幕, 在给定假设下)、以及其饱和与自适应坍塌(第三幕, 一条设计律)。所有底层定理及其严格度层级(已证 / 条件 / 标度)都在 companion 内核 [1] 中建立并制表; 此处我们复述它们 (§ 4) 并将其用于思维链监控, 墙与逆定理的自足重述见附录 B。

2 相关工作

既有工作分别提供了本文所整合的三种要素: 现象真实存在的证据、度量它的正确量, 以及使这些度量变得尖锐的高维机器。但没有工作把它们合成一个带价格的阈值。

现象是真实的、经验性的。 对 CoT 施加优化压力会诱发混淆式作弊, 其意图从轨迹中消失 [2]; 可监控性及其”脆弱窗口”被命名, 但停留在非形式化层面 [3]; 即便只监督输出也会外溢、推动出一条混淆的 CoT [5]; 综述则把奖励作弊刻画为把高维目标压缩进低维代理的结构性后果 [9]。这些确立了监控在压力下会退化这一事实——却没说它何时必然退化, 也没说有多陡。

正确的度量, 在固定工作点上。 CoT 可监控性曾被表述为轨迹与意图之间的互信息 $I(O; Z | X)$ [4], 以及决策论的隐写间隙 $1 - TV$ [6]; 二者都量化在给定压力下还剩多少信号, 也都明确指出缺失了最小可检测效应 / 阈值分析。隐写术表明完美安全的信道可能存在 [8], 且秘密串通随能力增

强 [7]。这些给出存在性与一个经验标度趋势;我们补上那个 分隔区域的阈值,并把趋势变成一个发散。

机器。 我们的尖锐性来自 Baik–Ben Arous–Péché [10] 的尖峰协方差相变,配以 [11, 12] 的特征向量重叠律;带约束(税)的分析使用凸高斯极小极大定理(CGMT) [13]。把这套 成熟的高维统计阈值移植进监控问题——并把它值函数读作一个价格——才是贡献;随机矩阵结果本身是 标准的。

替代的监控模型。 把我们的协方差尖峰模型与常被混淆的替代模型摆在一起会有帮助。均值 移位 / LDA 检测:若作弊是一阶(均值)签名,检测就是线性判别问题,给出平滑、无阈值的 erf 功效曲线——没有墙;这是”笨拙作弊”区,而把混淆建模为二阶正是产生尖锐 ρ^* 的原因。分类器 校准:训练好的监控器在可见特征上的准确率或校准是一个工作点摘要(若线性,即 LDA 情形);它报告的是 当下检测得多好,而非检测变得不可能时的压力。互信息度量 $I(O; Z | X)$ [4]:同样 在固定点量化残余信号,且如其作者所指出,缺少最小可检测效应分析;我们的 ρ^* 恰是那个缺失的阈值,而逆定理把” I 很小”变成”没有检验能成功”。隐写信道(1 – TV、安全编码) [6, 8]: 确立不可检测信道可以存在;我们补上优化何时被逼入其中、以及留在其外要付什么。这些替代品是 工作点或存在性陈述;我们的是一个带价格的阈值。

3 设置:玩具信道

我们把模型对监控器的相互作用提炼到其最小的忠实形式:从一个被部分观测、含噪的信道中恢复一个植入信号。一条轨迹是高维对象 $O \in \mathbb{R}^d$ ——可设想为监控器原则上能从 CoT 读到的特征。良性轨迹是无结构噪声;作弊 留下一个统计足迹,即沿某个隐藏方向 u 的额外结构分量。关键在于该足迹是二阶的:混淆式作弊 不移动轨迹的均值(那会显而易见),而是沿 u 扰动轨迹的协方差。形式上,作弊比特 $Z \in \{\text{clean}, \text{hack}\}$ 沿单位方向 $u \in \mathbb{R}^d$ 注入能量为 s^2 的各向异性方差尖峰:

$$\text{hack: } O = \xi + s \eta u, \quad \eta \sim \mathcal{N}(0, 1), \xi \sim \mathcal{N}(0, I_d); \quad \text{clean: } O = \xi; \quad \text{Cov}_{\text{hack}} = I_d + s^2 u u^\top. \quad (1)$$

监控器只分辨一个维度为 $d_{\text{mon}} = \alpha d$ 的子空间 S_{mon} ;它观测 $P_{\text{mon}} O$,并须从 n 个样本 恢复 u 。(对线性探针, P_{mon} 是字面投影;对 LLM 裁判,它是一个局部、经验的敏感子空间——扰动会翻转判决的那些方向——而 $\alpha, \rho, k_{\text{null}}$ 成为从该映射读出的有效量;见 § 6 与 表 3。)在优化压力 $\rho \in [0, 1]$ 下,模型拆分尖峰:能量的一个比例 $(1 - \rho)$ 留在 S_{mon} (”可见”),一个比例 ρ 被导入维度 $k_{\text{null}} = (1 - \alpha)d$ 的零信道 $S_{\text{mon}}^\perp$ 。因此 ρ 恰是对监控器隐藏的作弊能量比例。可见尖峰为 $s^2(1 - \rho)$; $P_{\text{mon}} O$ 的样本协方差在 $\sqrt{d_{\text{mon}}/n}$ 处有一条 Marchenko–Pastur 体边缘。

有四个数支配这个博弈,各有其运营解读。显眼度 s^2 是作弊足迹相对于轨迹噪声有多响。监控器 分辨率 $\alpha = d_{\text{mon}}/d$ 是监控器实际能读取的轨迹自由度比例;弱或粗糙的监控器 α 小。数据预算 n/d 是监控器每轨迹维度聚合多少条独立轨迹——它的统计功率。优化压力 ρ 是训练回路唯一移动的量:它是模型已学会导入监控器读不到的 $k_{\text{null}} = (1 - \alpha)d$ 个方向(零信道)的足迹比例。”强模型超出弱监控器”就是 $\rho \rightarrow 1$ 、 α 小、 n/d 小这个角。

注 1 (为何是协方差尖峰,而非均值移位). 混淆恰恰是从一阶签名转向二阶签名的动作:移动轨迹均值的作弊会被最粗糙的监控器抓住,所以在压力下 存活的作弊,是那些让平均轨迹保持不变、只扰动其形状的作弊。恢复于是成为尖峰协方差问题,携带一个真正的 Baik–Ben Arous–Péché 阈值;一

玩具符号	含义	真实 CoT 监控中的对应物
$O \in \mathbb{R}^d$	被监控轨迹	CoT tokens / 模型激活作为特征向量
$\alpha = d_{\text{mon}}/d$	监控器分辨率	监控器读取的轨迹自由度比例(探针秩、裁判带宽)
n/d	监控器数据预算	每轨迹维度的带标注轨迹数(探针/裁判统计功率)
s^2	作弊显眼度	作弊统计足迹的强度(暴露信号的信噪比)
ρ	优化压力	足迹被导入监控器零空间的比例
$k_{\text{null}} = (1 - \alpha)d$	可隐藏子空间	监控器无法分辨的轨迹方向

Table 1: 玩具信道与真实 CoT/轨迹监控之间的映射。在已部署监控器上估计右列是 Stage A.5–B 的目标;仪表 (§ 6)从轨迹统计量估计 α 、 s 、 k_{null} 。

个一阶(均值移位,LDA)模型则会给出平滑、无阈值的 erf 曲线,完全错过悬崖。我们报告的尖锐性,因此是诚实建模混淆的后果,而非玩具模型的假象。

记 $\gamma \equiv d_{\text{mon}}/n = \alpha/(n/d)$ 为有效纵横比, $\beta \equiv s^2(1 - \rho)$ 为可见尖峰强度。从 $P_{\text{mon}}O$ 恢复 u 是植入向量 / 尖峰协方差问题;其序参量是重叠 $\langle \hat{u}, u \rangle^2$ 。

4 结果:监控信道是内核的一个实例

§ 3 的玩具信道就是 companion 理论内核 [1] 的部分信道模型,读法为:分辨率 = 监控器带宽,预算 = 带标签轨迹,植入信号 = 混淆的 hack,零空间 = 监控器的盲方向。下面所有定理都在那里证明;我们以监控记号复述并使用它们,而附录 B 自足地重述承重的墙与逆定理,使本篇在内核在审时仍成立。全程 $\gamma = d_{\text{mon}}/n = \alpha/(n/d)$, $\beta = s^2(1 - \rho)$ 。

墙及其逆定理(内核命题 1–2)。 在比例区,恢复重叠 $\langle \hat{u}, u \rangle^2$ 对 $\rho < \rho^*$ 为正、对 $\rho > \rho^*$ 为零,

$$\rho^* = \left[1 - \frac{\sqrt{d_{\text{mon}}/n}}{s^2} \right]_0^1 = \left[1 - \frac{\sqrt{\alpha/(n/d)}}{s^2} \right]_0^1, \quad (2)$$

一个 Baik–Ben Arous–Péché 悬崖(边缘之上重叠 $\frac{1-\gamma/\beta^2}{1+\gamma/\beta}$ 、之下为 0), 随 $d^{-1/3}$ 变尖锐;一个 Le Cam 逆定理使 ρ^* 之上干净与 hack 轨迹毗连,故没有对投影轨迹的检验能一致检出 hack(“更聪明的分类器”无济于事)。操作上:带宽 α 、预算 n/d 的监控器一旦模型把 hack 足迹的 ρ^* 比例导入零信道就失明——且裁剪意味着 $s^2 \leq \sqrt{\gamma}$ 的监控器起始即盲。

有效秩(内核推论 1)。 决定墙的是已分辨协方差的稳定秩 $r_{\text{eff}} = \text{tr } \Sigma_{\text{mon}} / \|\Sigma_{\text{mon}}\| \leq d_{\text{mon}}$ ($\gamma_{\text{eff}} = r_{\text{eff}}/n$),对平坦/白化信道精确、一般情形为 deformed-MP 代理;低秩激活降低边缘、抬高 ρ^* ,故仪表从白化步骤读出 r_{eff} 而非名义 d_{mon} 。

价格(内核命题 3)。 为保持检测 $\text{AUC} \geq \tau$,模型须保留已分辨能量比例 $1 - \rho_{\text{max}} \geq \beta(\tau)/s^2 \geq \sqrt{\gamma}/s^2$,该地板随能力差距增大($n/d \rightarrow 0$)而增长;因比例 ≤ 1 ,这是一个可行性上限(一旦 $\beta(\tau) > s^2$,目标级监控不可行)。在正任务损失斜率 κ 下这是可监控性税 $\lambda_{\text{mon}} \geq \kappa\sqrt{\gamma}/s^2$; κ 任务特有,在 Stage A.5 校准。

墙是一个博弈值(内核命题 5-8)。 当模型选择其隐藏谱、监控器瞄准时,墙成为一个临界 hack 值:铺展到 K 维任务子空间对峰值监控器买一个因子 K 、对最优监控器买 $\sqrt{K}(V_{\text{spec}}^* = gK\sqrt{\gamma}, V_{\text{opt}}^* = g\sqrt{K\gamma})$,在内核的 A1-A4 下)。一个平凡聚合统计量把可藏值 cap 在单方向尺度 $\Theta(g\sqrt{\gamma})$ 、与 K 无关(内核命题 7),故铺展自我拆台;而一个瞄准(公开)奖励结构、测其总方差的自适应监控器坍塌墙, $V_{\text{adapt}}^* = \Theta(g\sqrt{K_{\text{pool}}/n}) \rightarrow 0$ (内核命题 8, B1-B4)。安全解读:稳健监控关乎看哪里、而非更好的分类器——无瞄准的原始带宽只抬高噪声地板(内核关于 $\sqrt{\alpha}$ 单调性的注),瞄准使之坍塌。余下一个区是覆盖博弈 $K_{\text{pool}} > d_{\text{mon}}$ (任务比带宽更丰富),core 将其刻画为斜坡(检测对覆盖比例线性)、而非无预警的坍塌;精确律留开。

为何是悬崖(内核定理 1)。 尖锐性特属于混淆 hack 的二阶(协方差尖峰)足迹:在部分信道族内,墙是悬崖当且仅当足迹二阶;一阶(均值移位)线索给出光滑、无阈值的 erf 曲线(图 3),而奖励模型过优化是族外的光滑泛化误差。重尾激活使朴素协方差估计器失明,但鲁棒(空间符号)估计器恢复悬崖(内核的注,仿真支撑)——这是仪表在非高斯轨迹下的处方。

稳健监控器的设计原则。 分析是处方性的、非宿命的——它说如何把墙保持得高(四条杠杆都是内核 [1] 中的定理)。

- 瞄准奖励结构。足迹活在奖励被收集之处;一个分辨(公开)任务子空间的监控器直接测量它(内核命题 8)。瞄准胜过任何固定通用探针——而无瞄准的原始带宽只抬高噪声地板(内核关于 $\sqrt{\alpha}$ 的注)。
- 让分辨率匹配任务秩。保持 $\alpha d \geq K_{\text{pool}}$ 使任务子空间适配预算;低于此,覆盖博弈给隐藏者留下缝隙。
- 花掉数据预算。墙高按 $1/\sqrt{n}$ 标度:每维更多带标签轨迹驱动 $V^* \rightarrow 0$ (内核仿真)。
- 用二阶(协方差)检验。尖锐墙是协方差尖峰现象;均值/线性分类器是光滑的、错过该区(图 3);重尾轨迹下用鲁棒(空间符号)二阶统计量(内核的注)。
- 读墙;别等悬崖。仪表(§ 6)从轨迹统计量估计 $\hat{\rho}^*/V^*$ 及到它们的距离——AUC 在坍塌前不给预警。

5 Stage-A 数值验证

我们在一个 CoT 风味的玩具中确认内核的预言 [1],随后搭建通往真实思维链的经验桥。监控器把 $\hat{u}$ 估计为 n 条投影作弊轨迹样本协方差的顶特征向量,并按一个留出会话(session)的轨迹沿 $\hat{u}$ 的平均能量打分;检测 AUC 是在这类会话上作弊对干净的判别。以下所有数值均来自这套 Stage-A 协议的 CPU numpy/scipy 重新实现($\alpha = 0.5, s = 1.19$,故在 $n/d = 1$ 时 $\rho^* = 0.50$);没有任何值是手工设定的。墙、税与二分律面板以监控记号重现内核的图;surrogate 与 token 面板是本文特有的 CoT 贡献。

两个核心论断在玩具信道上都成立:墙的位置与闭式 (2) 吻合并随 d 变尖锐;税贴合地板 § 4 并在能力差距上线性发散。这些是图 1 和 2 的真实来源。




Figure 1: 监控墙(Stage A)。(a) 检测 AUC 对优化压力 ρ ; 在 $\rho^*=0.50$ (理论, 虚线) 处的坍塌随维度 $d \in \{100, 300, 900\}$ 变尖锐(真正相变的证据): AUC 从 $\rho=0.1$ 附近的 0.985 降至 $\rho=0.8$ 时的 0.53。(b) 更弱的监控器(更小 n/d) 在更低 ρ 处即被致盲: ρ^* 从 0.65 ($n/d=2$) 经 0.50 ($n/d=1$) 到 0.29 ($n/d=0.5$), 与 (2)(虚线) 吻合。

有限尺寸修正。 墙是大- d 陈述; 在有限 d 下 BBP 转变被抹平。顶样本特征值以 Tracy–Widom 速率 $d^{-2/3}$ 在边缘附近涨落, 经特征值映射转化为 ρ^* 周围宽度 $\Delta\rho \asymp c d^{-1/3}/s^2$ 的 ρ -窗口。经验上该转变(AUC 0.9 $\rightarrow$ 0.55) 在 $d \in \{600, 900\}$ 时占据 $[0.29, 0.57]$ 并随 d 收窄 (图 1a 阴影)。两个后果: 仪表以带(band)而非点报告 $\hat{\rho}^*$ (带宽是这个有限- d 修正加估计噪声); 且因窗口以 $d^{-1/3}$ 收缩, 更大的轨迹空间使墙在运营上成为更锐的悬崖——与“高维 模糊阈值”的通常直觉相反。该带不应被读作墙是否存在的不确定, 而只是关于在哪、精确到 $O(d^{-1/3})$ 。

基线: 墙是机制特有的。 为表明尖锐性是作弊模型而非我们检测器的性质, 图 3 在匹配显眼度下, 以三种监控器扫同一隐藏比例 ρ : 我们的协方差尖峰作弊由 BBP 检测器读取, 以及一个一阶 均值移位作弊由 LDA 检测器和一个校准线性分类器读取。只有协方差情形有墙——AUC 在 $\hat{\rho}^*$ 处降至随机; 均值移位检测器平滑下降, 并对每个 $\rho < 1$ 都高于随机 (一条 erf 曲线, 无阈值)。分类器只与其特征一样锐利: 在一阶(均值)特征上它跟随 LDA、无阈值; 尖锐墙恰因混淆式作弊是二阶(协 方差)签名才出现。这是 § 2 中讨论的仿真对应物。

图 4 封住了命题 1 与命题 1 的重合。以单一的信噪-阈值比 $\beta/\sqrt{\gamma}$ 为横轴, 估计序参量(恢复重叠)偏离零、检测序参量(似然比二阶矩 $\mathbb{E}_0[L_n^2]$)发散, 都发生在同一点 $\beta = \sqrt{\gamma}$ 。使我们估计量失明的墙, 与越过后没有检验一致的墙, 是同一道墙; 两个闭式都被仿真吻合。

Stage A.5: 涌现的隐藏与税校准(代理)。 Stage A 施加 ρ ; 信道图像能否在训练下存活的首个检验, 是让 ρ 自行涌现。我们用梯度上升训练一个路由策略, 以最大化一个规避奖励减去隐藏的能力代价, 对手是一个经验探针监控器(n 样本上的 Stage-A 估计量); 随监控压力 λ 上升, 策略学会把方差尖峰导入零信道, 于是 ρ 是涌现而非被设定的。(这是一个 受控代理: 策略是连续路由器, 而非 token 级 transformer, 那是 Stage B。)两个发现(图 5)。(i) 墙预测了受训策略上的坍塌。随 λ 增大, 涌现的 ρ 扫过 $\hat{\rho}^*$, 经验检测 AUC 在一个夹住预测 $\hat{\rho}^* = 0.50$ 的有限- d 转变窗口 $[0.29, 0.57]$ 处坍塌 (24 种子上的 $\text{mean} \pm \text{sd}$; 窗口以 $d^{-1/3}$ 收窄); $\mathbb{R}^d$ 中的梯度训练到达与精确 argmax 相同的最优, 并恰在墙




Figure 2: 可监控性税的发散(Stage A)。保持 $AUC \geq \tau=0.72$ 所需的保留可见能量 $T = 1 - \rho_{\max}$ 自上方贴合理论地板 $\sqrt{\alpha/(n/d)}/s^2$ (虚线),并随监控器变弱 / 能力差距 $1/\sqrt{n/d}$ 增大而发散(实测税从强监控器处的 0.43 升到弱监控器处的 0.87)。

处出现双稳——策略跳过 而非逗留,呼应命题 1 的悬崖。(ii) 税斜率。固定作弊价值 B ,把达成奖励 $B(1 - D_{\text{emp}})$ 对保留可见能量 $V = s^2(1 - \rho)$ 描述,得到一个有限边际斜率 $\kappa = |dR/dV| = 1.9 \pm 1.2$,它在墙处达峰,与 § 4 的临界性一致。斜率的值是任务特有的;可迁移的是 § 4 的结构——有限 斜率乘以发散的能地板,给出随 $n/d \rightarrow 0$ 发散的税。在真实 CoT 上校准该斜率是 Stage B。

Token-transformer 确认(协方差尖峰,RL)。 为检验该图像能否在离散性与含噪 RL 下存活,我们把连续路由器换成一个真正的单层因果自注意力 transformer (numpy,梯度校验过的反向传播),它输出一段简短的离散 CoT;CoT 的读出方向 w 即注入的尖峰方向,尖峰幅度 s^2 固定(故信噪比受控),策略由 REINFORCE 训练,使 w 指向一个大体可见的价值方向 v ,同时监控器惩罚 可见尖峰(压力 λ)。我们定性地阅读图 6:它问的是机制能否在离散性与 RL 噪声下 存活,而非它是否定量钉住墙(那是代理与大- d 的活)。两个稳健发现:随 λ 上升,涌现的隐藏 ρ 从 0.28 升到 0.51、越过 $\hat{\rho}^* = 0.50$ (6 种子均值),墙附近方差大——一次双稳跳跃,策略跃过 而非停在墙上(又是悬崖)——而作弊有效性 $\langle w, v \rangle^2$ 随 ρ 上升从 0.39 坍塌到 ≈ 0.12 (种子均值),税在真实 token 上被具体化。尖锐的 AUC 坍塌在 token 模型的小 $d=40$ 下未被分辨(转变 随 d 变尖锐,图 1a;定量的 $\hat{\rho}^*$ 与税斜率是代理的活,图 5); transformer 补充的是:涌现的隐藏与税在离散性与 RL 噪声下存活——通向 Stage B 的桥。

6 仪表:可监控性仪表

理论要对监督者有用,就必须能在墙之前、从比它所预测之物更廉价的量中被读出。等到检测 AUC 明显下降时,监控器已越过 ρ^* ;一个有用的诊断必须转而从监控器已在收集的统计量估计墙的位置与到它的当前 距离。可监控性仪表(Monitorability Meter)就是这个诊断——一个与框架无关、监控器侧的仪器,类比一个 影子价格表。它暴露四个调用:`null_channel_dim`(可隐藏子空间维度 k_{null} ,监控器算子之外残差协方差的 participation ratio)、`wall_estimate`(墙位置 $\hat{\rho}^*$ 及到它的当




Figure 3: 墙是协方差尖峰(混淆)作弊所特有的。匹配显眼下检测 AUC 对隐藏比例 ρ : 带 BBP 检测器的协方差尖峰作弊(红)在 $\hat{\rho}^* = 0.50$ 处降至随机; 由 LDA 检测器(蓝)或校准线性分类器(绿)读取的均值移位作弊平滑下降, 对所有 $\rho < 1$ 仍可检测。阈值是二阶机制的特征, 而非检测器的特征。

前距离, 带重采样带)、monitorability_price(每保留一 nat 的 $I(O; Z | X)$ 的边际任务损失)、以及 StoppingRule (“墙前止步”)。仪表是监督者侧的仪器: 与只看投影信道 $P_{\text{mon}}O$ 的监控器(或对手)不同, 仪表 离线运行、可访问完整轨迹嵌入 O ——这是分离 s^2 与 ρ 所需的(仅从 $P_{\text{mon}}O$ 只能辨识可见尖峰 $s^2(1 - \rho)$, 故仪表只能报告 $s^2(1 - \rho)$ 及 ρ 的一个下界)。它先从干净(非作弊)轨迹估计良性协方差 $\hat{\Sigma}_0$ 并白化, $O \mapsto \hat{\Sigma}_0^{-1/2}O$, 使反演-BBP 步看到各向同性噪声; 记 $\hat{C} = \frac{1}{n} \sum_i (\hat{\Sigma}_0^{-1/2}O_i)(\cdot)^\top$ 为白化样本协方差, 顶特征对 $\hat{\lambda}, \hat{u}, P_{\text{mon}}$ 秩 d_{mon} :

$$\begin{aligned} \hat{\alpha} &= d_{\text{mon}}/d, & \hat{s}^2 &= \hat{\beta} : \hat{\lambda} = (1 + \hat{\beta})(1 + \frac{d/n}{\hat{\beta}}) \text{ (反演 BBP 映射)}, \\ \hat{\rho} &= \|(I - P_{\text{mon}})\hat{u}\|^2, & \hat{k}_{\text{null}} &= \frac{(\text{tr } R)^2}{\text{tr}(R^2)}, \quad R = (I - P_{\text{mon}})(\hat{C} - \hat{\lambda}\hat{u}\hat{u}^\top)(I - P_{\text{mon}}), \end{aligned}$$

且由 (2), $\hat{\rho}^* = 1 - \sqrt{\hat{\alpha}/(n/d)}/\hat{s}^2$ 。这里 $\hat{s}^2$ 是反演 BBP 特征值映射恢复的总尖峰强度(一旦 $\hat{\lambda}$ 从体中脱离即有效), $\hat{\rho}$ 是其零分数, $\hat{k}_{\text{null}}$ 是未分辨块中残差协方差的 participation ratio。两个承重例程为:

```
estimate_channel(O, O_clean, P_mon, n):    # O: hack traces; O_clean: benign
    Sigma0 = cov(O_clean)                  # benign (noise) covariance
    Chat   = cov(Sigma0^(-1/2) @ O)        # WHITEN, then sample covariance
    lam, u = top_eigenpair(Chat)            # top spike eigenpair
    alpha  = rank(P_mon)/d
    s2 = solve lam = (1+s2)(1 + (d/n)/s2)  # inverse BBP map
    rho = norm((I - P_mon) @ u)^2           # null fraction of spike
    R = (I - P_mon)(Chat - lam*outer(u,u))(I - P_mon) # off-spike residual
    k_null = trace(R)^2 / trace(R @ R)      # participation ratio
    return alpha, s2, rho, k_null, u
```

```
wall_estimate(O, O_clean, P_mon, n):
```




Figure 4: 一道墙,两个序参量。对 $\beta/\sqrt{\gamma}$ (取 $\gamma=1$):(a) 估计墙——恢复重叠 $\langle \hat{u}, u \rangle^2$ 在 $\beta < \sqrt{\gamma}$ 时为零,恰在阈值处偏离零(命题 1);(b) 检测墙——似然比二阶矩 $\mathbb{E}_0[L_n^2] = (1 - \beta^2/\gamma)^{-1/2}$ 在毗连(不可检测)区有限,并在同一阈值处发散(命题 1)。标记为仿真;曲线为闭式。估计与检测阈值重合,故”没有估计量恢复作弊”与”没有检验检出它”是同一事件。

```
alpha, s2, rho, k_null, u = estimate_channel(0, 0_clean, P_mon, n)
rho_star = 1 - sqrt(alpha/(n/d))/s2 # Eq. (2)
band = bootstrap(resample 0; recompute rho_star) # width ~ d^-1/3 + noise
return rho_star, rho, band
```

```
StoppingRule(state, delta): # symptoms coincide (Prop. 4)
    rho_star, rho_now, band = wall_estimate(state.0, state.0_clean,
                                             state.P_mon, state.n)
    price = monitorability_price(state.0, state.Z) # lambda_mon
    if (rho_star - rho_now) < delta or price > budget:
        halt CoT-directed optimization # stop before the wall
```

每个调用都需要一个轨迹协方差和一个相对于模型训练小、但非亚维度的带标注探针集:上述尖峰与特征向量估计仅当样本量 n 与被分辨的有效维度相当时才一致——估计量生活在比例区 $n/d_{\text{mon}} = \Theta(1)$ ($\hat{\rho}^*$ 确实依赖 n/d),而非 $n \ll d_{\text{mon}}$ 。在此前提下,仪表无需对模型的白盒访问,故它可附着于任何监控器——线性探针、LLM 裁判或分类器——作为运行时护栏,而非事后审计。

线性探针 vs. LLM 裁判。 对线性监控器——一个读出为轨迹特征固定秩- d_{mon} 投影的探针或分类器——算子 P_{mon} 是精确的,上述估计量此时是字面的。LLM 裁判是非线性的:不存在显式 P_{mon} ,框架适用于它的局部线性化。有效分辨算子是裁判的敏感映射——改变其判决的轨迹扰动所张成的空间,即其在工作点处 Jacobian 的行空间——而 α 、 k_{null} 、 ρ 成为从该映射读出的有效量。此时尖锐墙是关于线性化信道的一阶陈述,在裁判于相关扰动尺度上局部线性处成立;强非线性(读取轨迹真正非线性特征的裁判)会引入可移动有效边缘的高阶项,不在当前分析内。表 3 记录两种情形下各估计量的读法。

操作要求(非可选)。 仪表的估计仅当其前提成立时才有效;每一条都是真正的要求,而非便利。




Figure 5: **Stage A.5(代理):涌现与校准。** (a) 在监控压力 λ (颜色)下训练的路由策略发展出涌现的隐藏 ρ ;当受训 ρ 越过预测墙 $\hat{\rho}^*=0.50$ (虚线)时,经验监控器 AUC 坍塌;阴影的有限- d 窗口 $[0.29, 0.57]$ (24 种子 $\text{mean}\pm\text{sd}$)夹住它。 (b) 可监控性税:达成奖励($\text{mean}\pm\text{sd}$) 对保留可见能量 $V = s^2(1 - \rho)$;边际斜率 $|dR/dV|$ 在墙 $V = \sqrt{\alpha/(n/d)}$ 处达峰,校准命题 4(b) 的斜率 $\kappa(1.9 \pm 1.2)$ 。

- 完整轨迹嵌入。分离 s^2 与 ρ 需要完整轨迹 O ,而非仅 $P_{\text{mon}}O$;仅从投影只能辨识可见尖峰 $s^2(1 - \rho)$ 。
- 干净协方差与白化。反演-BBP 步假设各向同性噪声;良性协方差各向异性时,原始顶特征值被噪声主导,故须先从干净轨迹估计 $\hat{\Sigma}_0$ 并白化轨迹(图 7a)。
- 超临界尖峰。 $\hat{s}^2$ 由反演 BBP 映射读出,要求顶特征值已从体中脱离;墙下仪表须从最后一次超临界读数外推。
- 比例样本量。估计量生活在 $n/d_{\text{mon}} = \Theta(1)$;当 $n \ll d_{\text{mon}}$ 时特征向量估计不一致、 $\hat{\rho}^*$ 不可靠。
- 秩感知的 $\hat{\rho}$ 。单一顶特征向量误读多尖峰作弊;追踪 $\text{top-}r$ 特征向量(图 7b)。

图 7 对这些做压力测试:各向异性噪声下需要白化,多尖峰作弊下需要 $\text{top-}r$ 估计量,而——对一个非线性(二次)裁判——扰动法恢复的有效 P_{mon} 与真实分辨子空间吻合(重叠 ≈ 1),故仪表通过表 3 的敏感子空间读法迁移到非线性监控器。

7 阶段计划(证据层级)

该论断分三个阶段验证,每阶段买到不同种类的信心,且每阶段带有一个能证伪它的条件。

Stage A(已完成)。闭式 BBP 墙与税地板,在玩具信道上确认:检测 AUC 在 ρ^* 处坍塌并随维度变尖锐——真正相变而非有限尺寸缓坡的标志——且税贴合 $\sqrt{\alpha/(n/d)}/s^2$ 并在能力差距中增长(图 1 与 2)。这隔离了机制;它尚未表明该机制就是语言模型内部运作的那个。

Stage A.5(代理已完成; § 5,图 5)。一个输出简短 CoT 的微型 transformer,被一个探针监控器(n 样本上的 Stage-A 特征向量估计量)监视——而非真实 LLM 裁判,后者属于 Stage B。我们对 CoT 施加优化压力,并问:(i) 轨迹-意图信息 $I(O; Z | X)$ 是否在由信道估计的 $(\alpha, n/d, s)$ 预测的 $\hat{\rho}^*$




Figure 6: **Token-transformer 的 Stage A.5(协方差尖峰,REINFORCE;6 种子)**。一个单层自注意力策略 输出离散 CoT,其读出方向即注入的尖峰。(a) 涌现隐藏 ρ 对监控压力 λ (mean $\pm$ sd;灰点为单个种子;阴影为极差): ρ 从 0.28 升到 0.51、越过 $\hat{\rho}^*=0.50$,墙附近方差大(双稳跳跃——悬崖)。(b) 税:作弊有效性 $\langle w, v \rangle^2$ 随涌现 ρ 越过墙而坍塌(从 0.39 到 ≈ 0.12)。尖锐的 AUC 坍塌在 $d=40$ 下未分辨(参见图 1a;尖锐 $\hat{\rho}^*$ 与斜率是代理的活,图 5)。

处坍塌,(ii) 仪表的止步规则是否在坍塌之前 触发。一个首个的、非 token 代理已确认 (i)——涌现的 ρ 在预测位置越过墙——并校准了税斜率;一个由 REINFORCE 训练、梯度校验过的 token transformer 在离散 CoT 上重现了涌现隐藏与税(图 6)。留给 Stage B 的是尖锐的大- d 坍塌,以及关键地,一个真实 LLM 监控器——至今没有任何部分用过它。这一阶段钉住命题 4 中那个唯一的自由斜率。

Stage B(已规定;GPU)。一个真实推理模型,在一个智能体编码环境(单元测试作弊)中的真实 LLM CoT 监控器 之下。两个条件使理论在规模上可反驳:墙必须出现在 $k_{\text{null}}/(n/d)$ 预测之处——而非某个任意拟合的压力——且税必须 随能力差距标度而非饱和。若任一失败,则该相变不是支配真实 CoT 监控的现象,我们将如实报告。

8 局限与新颖性边界

模型的范围。 结果描述的是一个风格化的高斯信道;从” CoT 可监控性”到 $(\alpha, n/d, s, \rho)$ 的映射是一个待落地(Stage A.5/B)的建模设定。两个假设承载尖锐性并界定范围。其一,作弊签名被取为纯二阶(协 方差尖峰);真实作弊在多大程度上保留一阶(均值)分量,转变就在多大程度上从悬崖软化 为缓坡, ρ^* 就成为 最陡下降的位置而非真正的零点。故该论断对恰恰驱动该问题的混淆式作弊最尖 锐,对笨拙作弊最弱——正是有用的 出错方向。其二,税的任务损失斜率(保留可见能量 $\mapsto$ 放弃奖励) 不是推导出的;只有其发散是,斜率是 Stage A.5 校准的那一个量。

承重常数。 结果的价值系于命题 1 的尖锐常数。我们以闭式推导并与仿真吻合 (§ 4);残余风险是 经验的而非解析的——真实 CoT 信道是否位于 $\beta_{\text{sig}} = 0$ 阈值起作用 的比例区。若不然,结果优雅地 退化为重述一个已知的存在性界,这正是我们标出边界而非粉饰它的原因。

估计量	假设	失效模式
$\hat{s}^2$ (反演 BBP)	顶特征值已从体中脱离;单一主导尖峰	墙下 $\hat{\lambda}$ 重新没入体,故 $\hat{s}^2$ 未定义——仪表须从最后一次超临界读数外推
$\hat{\alpha} = d_{\text{mon}}/d$	固定、已知的监控器算子	自适应监控器重瞄 $S_{\text{mon}}(\alpha)$ 随时变);每轮用当前 S_{mon}
$\hat{\rho} = \ (I - P_{\text{mon}})\hat{u}\ ^2$	顶特征向量就是作弊方向	多尖峰(秩- r)作弊或墙附近噪声特征向量占主导会使 $\hat{\rho}$ 有偏;追踪 top- r
$\hat{k}_{\text{null}}$ (participation ratio)	去尖峰后残差协方差被良好近似	重尾 / 结构化轨迹噪声抬高该比值
$\hat{\rho}^*$	比例型高斯区;二阶(协方差)作弊	均值移位作弊给出平滑曲线(无尖锐 ρ^*); $n \ll d$ 破坏该估计

Table 2: 可监控性仪表的估计量假设与失效模式。首行与末行是操作性要点:墙估计是一次超临界外推,而尖锐性预设了比例区中的混淆式(协方差尖峰)作弊。经验规则:用 $n/d_{\text{mon}} \gtrsim 1$ (估计量所在的比例区);把 $\hat{\rho}^*$ 报告为一个自助带而非一个点,带宽 $\sim O(d^{-1/3})$ (有限尺寸)加估计噪声,随 $n/d_{\text{mon}} \downarrow 1$ 变宽。

量	线性探针(精确)	LLM 裁判(有效、线性化)
P_{mon}	固定秩- d_{mon} 读出投影	裁判在工作点处 Jacobian 的行空间
$\alpha = d_{\text{mon}}/d$	探针秩除以 d	Jacobian 有效秩除以 d
$\hat{s}^2, \hat{\rho}$	白化协方差上的反演-BBP	同上,基于局部线性化轨迹特征;高阶项被丢弃
$\hat{\rho}^*$	精确阈值	一阶阈值;在局部线性区有效

Table 3: 为线性探针(精确)与 LLM 裁判(一种有效、线性化的分辨率)读取仪表估计量。对裁判,经验校准 P_{mon} ——扰动轨迹并记录哪些方向翻转判决。

自适应监控器与共同演化。 我们固定监控器子空间 S_{mon} ;真实监督者可能在训练中重瞄它,投影到作弊当前所在的方向。这把墙变成移动靶,把交互变成动态博弈。两点评述界定其影响。其一,我们的结果是逐轮陈述:在任何固定 S_{mon} 处墙都成立,故自适应监控器买到的是时间而非豁免——每次重瞄重置 ρ ,但模型在新零信道里重新隐藏。其二,重瞄并非免费:扩大被分辨子空间抬高 α ,但在固定标注预算下降低每方向数据预算 n/d ,而这降低 ρ^* (图 1b)——故一个跨更多方向追逐作弊的监控器,在每个方向上更快地把自己致盲。因此税论证递归,而完整的模型对自适应监控器博弈的均衡是自然的下一个对象(命题 1 的 Stackelberg 版本);§ 4 解决了监控器能瞄准公开任务子空间的情形(§ 4:墙坍塌),并把覆盖区留开。

多尖峰(低秩)作弊。 我们建模秩一作弊。一个秩- r 作弊沿正交方向注入尖峰 $s_1^2 \geq \dots \geq s_r^2$, 各有其零分数 ρ_i 。监控器恢复方向 i 当且仅当其可见尖峰越过边缘, $s_i^2(1 - \rho_i) > \sqrt{\gamma}$, 故存在一个逐尖峰墙 $\rho_i^* = 1 - \sqrt{\gamma}/s_i^2$;作弊在每个尖峰都亚临界时被完全隐藏,而税是逐尖峰能量地板之和。因此低秩作弊可保留若干显眼分量可见(诱饵),同时把微妙分量(s_i^2 接近 $\sqrt{\gamma}$)滑到边缘之下——这是混淆的




Figure 7: 仪表压力测试。(a) 各向异性良性噪声:原始 s^2 误差随噪声条件数增长,而白化使其保持平坦——白化是必需的,非可选。(b) 多尖峰作弊(零分数分散):top-1 估计量有偏;top- r 估计量追踪均值 ρ 。(c) 非线性(二次)裁判:经验敏感子空间在各非线性强度下恢复真实分辨子空间(重叠 ≈ 1),验证 LLM 裁判的有效- P_{mon} 读法。

多尖峰类比,也是监控器有限预算 n/d 须在 r 个方向间分摊的情形。秩- r 阈值与最优诱饵分配是一个干净的延伸。

我们主张与不主张什么。 我们恰好主张三件事:一个尖锐阈值 ρ^* 、一个发散的能量地板(以及在正斜率假设下,一个发散的任务税)、以及一个可读性的几何定价单位。我们不主张混淆可能(已知 [8, 7])、有限监督会扭曲目标(已知 [9])、或一个更好的监控器。贡献与这三者正交:优化何时被逼越过,以及保持可读要付什么。

9 结论

监控是悬崖式失效,而非缓坡。越过一个几何设定的压力 ρ^* ,监控器与作弊的恢复重叠消失、没有检验能一致检出它,坍塌随系统增大而变尖锐,而为保持可检测所需的可见能量地板在绝对量上无界增长——直到一旦它超过总预算,就无法把模型保持在目标级可检测,监控器被直接击败。运营解读令人不安:一个报告健康 AUC 的监控器,并非握着一可以花掉的安全裕度,而是站在一道从其自身读数看不见边缘的悬崖旁。这正是可监控性仪表的用途——估计边缘的位置与到它的当前距离,使监督者能在墙前止步,而非事后才发现它。

结果对恰恰驱动该问题的混淆式作弊最尖锐,而其真实-CoT 实例化——语言模型轨迹是否位于阈值起作用的区?——是 Stage A.5 与 B 被构造来回答的开放经验问题。最后,同一台机器可移植到”强优化器遇上不完美检查”的姊妹博弈:策略对奖励模型(过优化起点)与策略对验证器(覆盖)。监控墙是最干净的实例;它们共同暗示一个奖励作弊中的尖锐阈值的统一纲领,其反复出现的对象是一个临界压力、一个发散的价格、以及一个优化器学会藏身其中的零信道。使隐藏谱与监控器的瞄准内生(§ 4),把阈值变成一个博弈值——一个临界能力 V^* ——并锐化安全解读:墙只在监控器瞄不准或数据匮乏时保护隐藏者;一个瞄准公开、可覆盖任务子空间、并测量其总方差的自适应监控器坍塌该墙(§ 4, B1–B4)。余下的是瞄准不足以奏效的那个区——任务子空间大于监控器预算——其覆盖博弈在 core 中被刻画为斜坡(canonical 模型, p_{det} 对覆盖比例线性),完整律留开。

A 可复现性

所有实验仅用 CPU(numpy 2.4 / scipy 1.17)。代码。 每张图都由一个简短自包含的脚本生成;这些脚本,连同可监控性仪表的一个参考 numpy 实现 (§6 的估计量: `null_channel_dim`, `wall_estimate`, `monitorability_price`, `StoppingRule`) 以及梯度校验过的微型 transformer, 随投稿提供并将在发表时释出;该仪表是研究参考实现,而非硬化库,且带有 §6 所列的失效模式。各处检测 AUC 均用同一会话检测器:监控器把 $\hat{u}$ 估计为 n 条投影作弊轨迹样本协方差的顶特征向量,再按留下的 b 条轨迹会话沿 $\hat{u}$ 的平均能量打分,并在会话上报告 AUC (作弊对干净)。

玩具信道(图 1-4)。 $\alpha = 0.5, s = 1.19 (s^2 = 1.414)$, 故在 $n/d = 1$ 时 $\rho^* = 0.50$ 。图 1a: $d \in \{100, 300, 900\}, n = d$; 会话 $b = 120, 100$ 个会话, 2 次试验。图 1b: $n/d \in \{0.5, 1, 2\}$ 。图 2: 税 = $1 - \rho_{\max}$ (在 $\tau = 0.72$) 对地板 $\sqrt{\alpha/(n/d)}/s^2$ 。图 4b(逆定理): $\mathbb{E}_0[L_n^2] = \mathbb{E}_{u,u'}(1 - \beta^2 \omega^2)^{-n/2}$ ($\omega = \langle \tilde{u}, \tilde{u}' \rangle$) 蒙特卡洛, $p = 6000, 4 \times 10^5$ 对, 在墙下方与 $(1 - \beta^2/\gamma)^{-1/2}$ 吻合到 3-4 位。脚本: `fig1.py`, `fig2.py`, `fig3_two_walls.py`, `cgmt_check.py`, `converse_check.py`。

有效秩 (§4)。当良性协方差稳定秩为 r_{eff} (在其值域内白化) 时, 实测检测墙随 $\sqrt{r_{\text{eff}}/n}$ 移动: 在 $d_{\text{mon}}=300, n=400$ 、通用 Haar 尖峰下, 墙随 $r_{\text{eff}} \in \{50, 100, 200, 300\}$ 上升, 并在 $r_{\text{eff}}=d_{\text{mon}}$ 处与 $\sqrt{d_{\text{mon}}/n}$ 相遇 (对 r_{eff} 单调, 受 $\text{AUC} = 0.75$ 越阈影响在精确边缘之上有一个有限- n 偏移)。脚本: `reff_check.py`。

连续代理(图 5)。训练一个路由策略 $w \in \mathbb{R}^d$ (梯度上升; 对照精确 $\arg\text{-max}$ 校验) 以最大化规避奖励减去隐藏的二次能力代价; $\rho = \|P_{\text{mon}}^\perp w\|^2$ 涌现。会话检测器在 $d_{\text{eval}} = 600$ 给出 $\text{AUC}(\rho)$; 带为 24 种子上的 $\text{mean} \pm \text{sd}$; 有限- d 转变窗口 ($\text{AUC } 0.9 \rightarrow 0.55$) 为 $[0.29, 0.57]$, 夹住 ρ^* 并随 $d^{-1/3}$ 收窄。税斜率 $\kappa = 1.9 \pm 1.2$ (奖励 = $2(1 - \text{AUC})$, 墙处斜率在种子上取值)。脚本: `fig4_ci.py`。

Token transformer(图 6)。一个单层因果自注意力策略(numpy, 手写反向传播, 梯度校验最大相对误差 4×10^{-7}): $d_{\text{model}} = 16$, 词表 48, CoT 长度 8。由 REINFORCE 训练 (Adam, 学习率 0.015, 批大小 64, 滑动均值基线, 约 900 回合), 自 $\lambda=0$ 预训练初始化。CoT 读出方向 $w = \text{normalize}(\sum_t E_{\text{out}}[\text{tok}_t])$ 即注入尖峰; 尖峰幅度 $s^2 = 1.414$ 固定 (受控 SNR); 奖励 = $\langle w, v \rangle^2 - \lambda \sigma(\kappa(s^2 \|P_{\text{mon}} w\|^2 - \text{edge}))$, 其中 v 大体可见; 监控器预算 $n = d = 40$ 。点为 3 种子上的 $\text{mean} \pm \text{sd}$; 小 $d=40$ 使 AUC 坍塌在有限尺寸下偏宽 (参见图 1a)。脚本: `tt_model.py`, `tt_spike.py`, `tt_ci.py`。

双时标动力学 (§4, 内核仿真)。慢策略 ρ_k / 快监控器 $\hat{D}_k$ 随机逼近, $a_k = 0.03/(1+k/400)^{0.6}$, $b_k = 0.30/(1+k/400)^{0.51}$ ($a_k/b_k \rightarrow 0$); 快变量以估计噪声 $1/\sqrt{n}$ ($n=200$) 追踪 BBP 可检测性 $D^*(\rho)$; 慢变量带 SGD 噪声 0.15 上升 $J = \lambda(1-D^*) - 0.9\rho$; 16 种子。收敛的 ρ_∞ 越过势垒后与 $\rho^*=0.50$ 相遇; 亚稳带是隐藏盆为全局最优、但 SA 仍被困在可见盆的区间。脚本: `twotimescale.py`。

B 自足内核: 墙与逆定理, 以监控记号

为自足起见, 我们重述两条承重结果——墙与其逆定理——并以监控记号勾勒其证明, 使本篇的中心主张无需内核论文即可成立。(这是同一个 BBP/CGMT 论证; 完整证明与博弈/饱和/自适应结果见 [1]。)

设置,重述。 一个混淆 hack 沿单位方向 $u \in \mathbb{R}^d$ 注入能量为 s^2 的方差尖峰;监控器分辨一个 $d_{\text{mon}} = \alpha d$ 维子空间,从 n 条轨迹估计 u 。压力 ρ 下它把一部分 ρ 导入零信道,留下可见尖峰 $\beta = s^2(1 - \rho)$;记 $\gamma = d_{\text{mon}}/n$ 。

命题 1 (监控墙 + 逆定理,自足). 在比例区 $d_{\text{mon}}, n \rightarrow \infty$ 、 $d_{\text{mon}}/n \rightarrow \gamma$:(i) 恢复重叠 $\langle \hat{u}, u \rangle^2 \rightarrow [(1 - \gamma/\beta^2)/(1 + \gamma/\beta)]_+$,正当且仅当 $\beta > \sqrt{\gamma}$,即零当且仅当 $\rho \geq \rho^* = [1 - \sqrt{\gamma}/s^2]_0$;(ii) 对 $\beta < \sqrt{\gamma}$,干净与 hack 轨迹律毗连,似然比二阶矩 $\mathbb{E}_0[L_n^2] \rightarrow (1 - \beta^2/\gamma)^{-1/2} < \infty$,故没有对 n 条投影轨迹的检验能一致检出 hack。两阈值重合。

证明梗概。投影轨迹有总体协方差 $I_{d_{\text{mon}}} + \beta \tilde{u} \tilde{u}^\top$ ($\tilde{u}$ 为单位可见分量)。由 BBP,顶样本特征值离开 Marchenko–Pastur 体当且仅当 $\beta > \sqrt{\gamma}$,特征向量重叠如 (i); 边缘之下重叠为 0、任何据 $\hat{u}$ 构造的统计量渐近无信息。因 $\beta = s^2(1 - \rho)$,边缘在 ρ^* 处越过。对 (ii), u 均匀先验下的单尖峰 Le Cam 二阶矩为 $(1 - \beta^2/\gamma)^{-1/2}$,有限当且仅当 $\beta < \sqrt{\gamma}$; 有界二阶矩给出毗连,从而无一致检验。尖锐常数来自 CGMT 不动点 $\Phi_{\text{AO}}(\mu) = \sqrt{\gamma(1 - \mu^2)} + \sqrt{1 + \beta\mu^2}$,其在 $\beta = \sqrt{\gamma}$ 处的 $\mu = 0$ /非平凡分支分岔重现 (i) 与 Marchenko–Pastur 边缘 [1]。□

References

- [1] The Wall, the Game, and the Cliff Criterion: sharp thresholds for recovering a planted signal through a partial channel. Companion 理论内核(含全部证明、CGMT 不动点、博弈值、饱和、自适应坍塌与悬崖判据)。
- [2] B. Baker et al. (OpenAI). Monitoring reasoning models for misbehavior and the risks of promoting obfuscation. arXiv:2503.11926, 2025.
- [3] T. Korbak et al. Chain-of-thought monitorability: a new and fragile opportunity for AI safety. arXiv:2507.11473, 2025.
- [4] Analyzing and improving CoT monitorability through information theory. arXiv:2602.18297, 2026.
- [5] Output supervision can obfuscate the chain of thought. arXiv:2511.11584, 2025.
- [6] Decision-theoretic steganography in LLM monitoring. arXiv:2602.23163, 2026.
- [7] S. Motwani et al. Secret collusion among AI agents. NeurIPS 2024, arXiv:2402.07510.
- [8] C. Schroeder de Witt, S. Sokota, J. Z. Kolter, J. Foerster, M. Strouse. Perfectly secure steganography using minimum entropy coupling. ICLR 2023, arXiv:2210.14889.
- [9] Reward hacking in the era of large models: mechanisms, emergent misalignment, challenges. arXiv:2604.13602, 2026.
- [10] J. Baik, G. Ben Arous, S. Péché. Phase transition of the largest eigenvalue for nonnull complex sample covariance matrices. Ann. Probab. 33(5):1643–1697, 2005.

- [11] F. Benaych-Georges, R. R. Nadakuditi. The eigenvalues and eigenvectors of finite, low-rank perturbations of large random matrices. *Adv. Math.* 227(1):494–521, 2011.
- [12] D. Paul. Asymptotics of sample eigenstructure for a large-dimensional spiked covariance model. *Statist. Sinica* 17(4):1617–1642, 2007.
- [13] C. Thrampoulidis, S. Oymak, B. Hassibi. Regularized linear regression: a precise analysis of the estimation error. *COLT, PMLR* 40:1683–1709, 2015.
- [14] L. Le Cam. *Asymptotic Methods in Statistical Decision Theory*. Springer, 1986.
- [15] A. Onatski, M. J. Moreira, M. Hallin. Asymptotic power of sphericity tests for high-dimensional data. *Ann. Statist.* 41(3):1204–1231, 2013.
- [16] A. Onatski, M. J. Moreira, M. Hallin. Signal detection in high dimension: the spiked rank-one case. *Ann. Statist.* 42(1):225–254, 2014.
- [17] A. Perry, A. S. Wein, A. S. Bandeira, A. Moitra. Optimality and sub-optimality of PCA I: spiked random matrix models. *Ann. Statist.* 46(5):2416–2451, 2018.